

Piattaforma AI Assistente Aziendale — Studio di Fattibilita e Archi

Autore: Elios Scoglio

Data: 2026-06-07

Versione: 1.0 — Studio esplorativo

Status: Draft per discussione

Executive Summary

Questo documento esplora la fattibilita di costruire una piattaforma AI personalizzabile per PMI che integri:

- Client desktop/web con multi-agente e multi-modello
- Knowledge base aziendale ibrida (Qdrant vector + Neo4j graph)
- Interazione con strumenti aziendali (email, browser, file, ERP)
- Dashboard di gestione per consulente (multi-cliente)

Il modello di business e: consulenza + piattaforma proprietaria. Arrivi in azienda, capisci i processi, costruisci KB e agenti, consegni un sistema funzionante. La piattaforma e il veicolo tecnico del servizio CAIO-aaS.

Evoluzione prevista: PMI (servizio diretto) -> SaaS multi-tenant -> Franchising/licenza per altri consulenti.

PARTE 1 — Valutazione dell'idea

Perche e una buona idea [verificato]

- Il mercato c'e: il 73% delle PMI italiane non ha adottato AI (Osservatorio PoliMI 2024). Quelle che provano si perdono tra tool sparsi senza governance.
- Il gap reale: non mancano i modelli AI — manca chi assembla il sistema (KB + agenti + integrazioni) calato sul contesto aziendale specifico.
- Il tuo vantaggio competitivo: sei uno dei pochissimi in Italia che ha gia costruito agenti AI in produzione (Agente-TO-EliosArch, Agente-TO-EliosAnalista), conosce MCP, e ha un framework consulenziale completo (portfolio Vision).
- Timing: i costi dei modelli stanno crollando (Qwen/DeepSeek/Llama gratis o quasi). Chi costruisce l'infrastruttura di orchestrazione ADESSO avra un moat quando il mercato esplode.
- Lock-in positivo: la KB aziendale e gli agenti personalizzati creano retention altissima. Il cliente non puo "portarsi via" facilmente il sistema configurato.

Rischi principali [da mitigare]

Rischio	Impatto	Mitigazione
Mercato affollato di tool generici (ChatGPT Teams, Copilot, etc.)	Alto	Differenziarsi su personalizzazione + KB + agenti specifici, non sul "c
Tempi di sviluppo troppo lunghi prima del primo euro	Alto	MVP minimale in 4-6 settimane, non piattaforma completa
Dipendenza da API di terzi (OpenAI, Anthropic)	Medio	Multi-model fin dal giorno 1, includere modelli self-hosted
Cliente PMI non capisce il valore e compara con "ChatGPT gratis"	Alto	Vendere risultati (ore risparmiate), non tecnologia


Sfida critica

Il peggior outcome se sbagli: investi 6+ mesi a costruire una piattaforma troppo complessa che nessun cliente usa perche troppo tecnica o troppo generica. Il rischio non e tecnico — e di product-market fit.

Mitigazione: costruisci per UN cliente reale, con UN problema specifico, poi generalizza.

PARTE 2 — Architettura della Soluzione

2.1 — Componenti principali



2.2 — Stack Tecnologico Raccomandato

Backend / Orchestrator

Componente	Opzione raccomandata	Alternative	Costo
Linguaggio backend	TypeScript (Node/Bun)	Python (FastAPI)	Free
Framework agenti	LangGraph (open source)	CrewAI, AutoGen, Haystack	Free

Orchestrazione LLM | LiteLLM (proxy multi-model) | OpenRouter, portkey.ai | Free (self-hosted)
Knowledge Base vector | Qdrant (self-hosted) | ChromaDB, Weaviate, Milvus | Free
Knowledge Base graph | Neo4j 5 Community + Cypher | Memgraph (scartato), FalkorDB, Apache AGE | Free (vedi ADR-001)
RAG pipeline | LlamaIndex | LangChain, Haystack | Free
DB applicativo | PostgreSQL + Drizzle ORM | SQLite (MVP), Supabase | Free
Auth | Lucia Auth o Better Auth | Clerk (\$), Auth.js | Free
Queue/Jobs | BullMQ (Redis) | Inngest, Trigger.dev | Free
Hosting | Hetzner VPS (CX31: ~15 EUR/mese) | Contabo, OVH, self-hosted | 15-50 EUR/mese

Modelli AI (costo per 1M token output)

Provider	Modello	Costo output/1M	Note
Alibaba Qwen	Qwen2.5-72B (via Together/Fireworks)	~\$0.90	Ottimo rapporto qualita/prezzo
DeepSeek	DeepSeek-V3	~\$0.28	Economicissimo, buona qualita
Meta Llama	Llama 3.3 70B (self-hosted Ollama)	\$0 (solo compute)	Gratis su hardware proprio
Google	Gemini 2.0 Flash	~\$0.30	Veloce, economico, context lungo
Anthropic	Claude Sonnet 4	~\$15	Qualita top, costoso — usare per task critici
OpenAI	GPT-4o-mini	~\$0.60	Buon compromesso
Mistral	Mistral Large	~\$2.40	EU-based, GDPR friendly

Strategia costi: routing intelligente. Il 90% dei task (risposta FAQ, riassunti, classificazione) va su DeepSeek/Qwen. Solo il 10% (analisi complesse, decisioni critiche) va su Claude/GPT-4o.

Client Desktop

Opzione	Pro	Contro	Costo
Electron + React	Massima flessibilita, accesso completo a OS, ecosistema ricco	Pesante (~100MB), memoria alta	Free
Tauri + React/Svelte	Leggero (~5MB), nativo, Rust backend sicuro	Ecosistema piu giovane, meno plugin	Free
Progressive Web App (PWA)	Zero install, funziona su tutti i device, aggiornamenti istantanei	Accesso OS limitato (no file system completo, no	
Web app + Agent locale	Web app per chat + un piccolo agent installato per azioni OS	Best of both worlds, piu complesso da deployare	Free

La mia opinione [probabile]:

Per il tuo caso raccomando: Web app (PWA) + Agent locale leggero (opzionale).

Ragionamento:

- La web app e piu facile da aggiornare, non richiede installazione, funziona su qualsiasi device, e piu semplice da mantenere per un singolo sviluppatore.
- Per l'interazione con PC/email/browser: un agent locale leggero (un piccolo servizio Node/Python che gira in background) puo fare il bridge. Il cliente installa un .exe/.msi e quello fa da proxy locale.
- Alternativa: per l'email puoi usare OAuth + Microsoft Graph / Google API senza agent locale.
- Per il file system: un servizio locale e quasi obbligatorio se vuoi accesso a file locali del cliente.

Evoluzione: parti solo con web app (settimane 1-8), aggiungi l'agent locale quando hai il primo cliente che lo richiede.

PARTE 3 — Cosa Esiste sul Mercato (Build vs Buy vs Integrate)

3.1 — Piattaforme complete (competitor/ispirazioni)

Piattaforma	Cosa fa	Prezzo	Open Source?	Valutazione per te
Dify.ai	AI workflow builder, RAG, agenti, multi-model	Free self-hosted, cloud da \$59/mese	Si (Apache 2.0)	Candidato #1 come base — piu
Langflow	Visual agent builder, RAG, multi-model	Free self-hosted	Si (MIT)	Buono per prototipazione veloce
n8n + AI nodes	Workflow automation con nodi AI	Free self-hosted	Si (Fair-code)	Ottimo per integrazioni, meno per chat
OpenWebUI	Frontend ChatGPT-like per Ollama/OpenAI	Free	Si (MIT)	Candidato #1 come client
AnythingLLM	Workspace AI con RAG, agenti, multi-model	Free self-hosted	Si (MIT)	Buon all-in-one per PMI
Flowise	Low-code LLM orchestration + RAG	Free self-hosted	Si (Apache 2.0)	Alternativa visual a Dify
LobeChat	Client AI multi-model con plugin	Free self-hosted	Si (MIT)	Bello come client, meno come piattaforma
LibreChat	Clone ChatGPT multi-provider	Free	Si (MIT)	Solo chat, no KB/agenti custom
Khoj	AI assistant personale con RAG	Free self-hosted	Si (AGPL)	Piccolo ma interessante per personal use
Quivr	"Second brain" con RAG	Free self-hosted	Si	Buono per KB, limitato come agenti

3.2 — Tool specializzati per componenti singoli

Componente	Tool open source	Note
Knowledge Base a grafo	Neo4j + LlamaIndex GraphRAG	Microsoft ha rilasciato GraphRAG open source
RAG	LlamaIndex, LangChain, Haystack	LlamaIndex e il piu maturo per RAG enterprise
Multi-model routing	LiteLLM, OpenRouter	LiteLLM e il migliore per self-hosted
Agenti	LangGraph, CrewAI, AutoGen	LangGraph = piu flessibile; CrewAI = piu semplice
MCP Server	@modelcontextprotocol/sdk	Tu gia lo conosci
Browser automation	Playwright, Puppeteer, Browser-Use	Browser-Use e specifico per AI
Email	Microsoft Graph API, Gmail API	OAuth, no password
Desktop agent	Tauri sidecar, Electron	Tauri piu leggero
Vector DB	Qdrant, ChromaDB, Milvus	Qdrant = miglior rapporto funzionalita/performance

3.3 — La raccomandazione: Integrate, non costruire da zero

[probabile] L'approccio migliore per te e un "platform assembly" — non un build from scratch.

```
ARCHITETTURA RACCOMANDATA — MVP (4-8 settimane)
=====

Layer 1 — Client:      OpenWebUI (fork o white-label)
                      + customizzazione per multi-tenant
                      + branding per cliente

Layer 2 — Backend:     Dify.ai (self-hosted)
                      + workflow/agenti custom per cliente
                      + RAG con documenti aziendali

Layer 3 — KB:          Qdrant (vector) + Neo4j (graph, fase 2)
                      + ingest pipeline (PDF, email, web)

Layer 4 — Models:      LiteLLM proxy
                      + routing per costo/qualita
                      + Ollama per modelli locali

Layer 5 — Integrazioni: n8n per workflow
                      + MCP server custom per tool aziendali

Layer 6 — Dashboard:   Custom (Next.js o SvelteKit)
                      + multi-tenant management
                      + billing (Stripe)
```

Cosa costruisci TU da zero (il tuo valore aggiunto):

- La dashboard consulente multi-tenant (gestione clienti, agenti, KB)
- I template di agenti per casi d'uso PMI (customer service, documentazione, reportistica)
- La metodologia di onboarding (come mappare processi aziendali -> agenti)
- I connettori specifici per tool italiani (fatturazione, PEC, SPID?)
- Il model router intelligente (quale modello per quale task, ottimizzando costi)

Cosa NON costruisci (usi open source):

- Il motore di chat (OpenWebUI/LobeChat)
- Il RAG engine (LlamaIndex/Dify)
- Il vector store (Qdrant)
- L'orchestratore LLM (LiteLLM)
- Le integrazioni standard (n8n)

PARTE 4 — Roadmap di Sviluppo

Fase 0 — Validazione (Settimane 1-2) [CRITICA]

Obiettivo: confermare che un cliente reale pagherebbe per questo.

- [] Identifica 2-3 PMI dal tuo network che hanno già provato ChatGPT ma non l'hanno integrato
- [] Fai una demo con Dify + OpenWebUI (esistenti, zero sviluppo) su un caso d'uso specifico loro
- [] Se dicono "quanto costa?", hai validato. Se dicono "carino ma...", approfondisci cosa manca
- [] Raccogli i 3 use case più richiesti

Investimento: 0 EUR, 2-3 giorni del tuo tempo.

Fase 1 — MVP (Settimane 3-8)

Obiettivo: primo cliente pagante con un sistema funzionante.

Settimana	Cosa	Deliverable
3-4	Setup infrastruttura base	VPS Hetzner + Dify + LiteLLM + Qdrant
4-5	Configurazione per 1 cliente pilota	KB caricata, 2-3 agenti configurati
5-6	Client web personalizzato	OpenWebUI customizzato o semplice web app React
6-7	Integrazioni base	Email (OAuth), calendario, 1-2 tool del cliente
7-8	Test con utenti reali del cliente	Feedback, fix, stabilizzazione

3-4	Setup infrastruttura base	VPS Hetzner + Dify + LiteLLM + Qdrant
4-5	Configurazione per 1 cliente pilota	KB caricata, 2-3 agenti configurati
5-6	Client web personalizzato	OpenWebUI customizzato o semplice web app React
6-7	Integrazioni base	Email (OAuth), calendario, 1-2 tool del cliente
7-8	Test con utenti reali del cliente	Feedback, fix, stabilizzazione

Costo infrastruttura MVP: ~50-80 EUR/mese (VPS + dominio + email transazionale)

Pricing per primo cliente: 1.500-3.000 EUR setup + 300-500 EUR/mese hosting e manutenzione

Fase 2 — Multi-tenant (Mesi 3-6)

Obiettivo: 3-5 clienti attivi, dashboard consulente.

- [] Dashboard gestione clienti (Next.js/SvelteKit custom)
- [] Onboarding semi-automatizzato (template agenti per settore)
- [] Knowledge base a grafo (Neo4j) per relazioni complesse
- [] Agent locale per interazione PC (Tauri sidecar)
- [] Billing automatizzato (Stripe)
- [] Libreria di 10+ agenti template per casi d'uso comuni

Costo infrastruttura: ~150-300 EUR/mese (scaling con clienti)

Revenue target: 5 clienti x 400 EUR/mese = 2.000 EUR/mese ricorrente + setup

Fase 3 — Prodotto (Mesi 6-12)

Obiettivo: SaaS stabile, onboarding self-service per altri consulenti.

- [] Onboarding self-service (il consulente si registra e configura il suo tenant)
- [] Marketplace agenti (template condivisibili/vendibili)
- [] API pubblica per integrazioni
- [] Documentazione completa
- [] White-label per partner
- [] Modello franchising: consulente paga licenza piattaforma + revenue share

Pricing SaaS/Franchising [probabile]:

- Licenza base consulente: 99-199 EUR/mese (include fino a 5 clienti)
- Per-client add-on: 30-50 EUR/mese/cliente
- Enterprise (>20 clienti): custom
- Revenue share su AI usage: 10-20% del costo modelli

PARTE 5 — Confronto con Alternative di Mercato

5.1 — "Perche non uso semplicemente Dify/AnythingLLM e basta?"

Puoi farlo. Per i primi 1-2 clienti, Dify self-hosted e sufficiente. Ma il problema e:

- Non e multi-tenant: ogni cliente richiede un'istanza separata o configurazione manuale
- Non ha la dashboard consulente: non puoi gestire 10 clienti efficientemente
- Non ha i tuoi agenti specializzati: il valore aggiunto e la tua metodologia
- Non e brandizzabile: il cliente vede "Dify", non il tuo brand
- Non ha billing integrato: gestisci fatture manualmente

Quindi: Dify e il motore sotto il cofano, ma tu costruisci la carrozzeria.

5.2 — "Perche non uso ChatGPT Teams / Copilot per Microsoft 365?"

Criterio	ChatGPT Teams / Copilot	La tua piattaforma
Personalizzazione	Limitata (GPTs, prompt)	Totale (agenti, KB, workflow)
Knowledge base	Upload file (limitato)	RAG enterprise + grafo
Modello AI	Solo OpenAI / Solo Microsoft	Qualsiasi (routing per costo)
Costi per PMI 10p	~\$250-\$500/mese	~300-500 EUR/mese (tutto incluso)
Integrazioni	Solo ecosistema proprio	Qualsiasi (MCP, n8n)
Controllo dati	Cloud USA	Self-hosted EU / on-prem
Agenti specifici	No	Si, costruiti sui processi del cliente

Il tuo pitch: "ChatGPT e generico. Io ti costruisco un assistente che conosce la TUA azienda, parla con i TUOI sistemi, e costa meno."

5.3 — Alternative SaaS esistenti per consulenti AI

Piattaforma	Cosa offre	Prezzo	Limit
CustomGPT.ai	White-label chatbot con RAG	Da \$89/mese	Solo chat, no agenti
Botpress	Agent builder visual	Free tier	Complesso, orientato chatbot

Voiceflow | Conversational AI builder | Da \$50/mese | Orientato voice/chat, no agenti generici
Stack AI | No-code AI workflow per enterprise | Da \$199/mese | Costoso, orientato enterprise
Relevance AI | AI workforce/agents | Da \$99/mese | Buono ma costoso per PMI

Nessuno di questi offre il pacchetto completo: KB a grafo + multi-model + agenti custom + integrazioni PC + dashboard consulente + white-label. Questo e il tuo spazio.

PARTE 6 — Modello Economico

Costi fissi mensili (stimati)

Voce MVP (mese 1-3) Growth (mese 4-12)		
VPS Hetzner (CX31 + storage)	30 EUR	80-150 EUR
Dominio + SSL	5 EUR	5 EUR
Email transazionale (Resend)	0 (free tier)	20 EUR
API AI (LiteLLM -> providers)	50-100 EUR	200-500 EUR (ribaltato su clienti)
Monitoring (Grafana Cloud free)	0	0
Backup (Hetzner Storage Box)	5 EUR	15 EUR
Totale	~90-140 EUR/mese	~320-690 EUR/mese

Revenue model

Servizio	Prezzo	Tipo
Setup iniziale (audit + configurazione KB + agenti)	1.500-5.000 EUR	Una tantum
Hosting + manutenzione	300-800 EUR/mese	Ricorrente
Aggiunta agenti/integrazioni	500-2.000 EUR cadauno	Una tantum
Training team cliente	500-1.000 EUR	Una tantum
CAIO-aaS (governance + piattaforma)	1.500-4.000 EUR/mese	Ricorrente premium

Proiezione revenue (conservativa)

Mese	Clienti	MRR	Costo infra	Margine
3	1	500 EUR	100 EUR	400 EUR
6	3	1.500 EUR	200 EUR	1.300 EUR
9	5	3.000 EUR	350 EUR	2.650 EUR
12	8	5.000 EUR	500 EUR	4.500 EUR
18	12 + 2 consulenti	8.000 EUR	700 EUR	7.300 EUR

A questo si aggiungono i setup una tantum: 3-5 setup/mese x 2.500 EUR = 7.500-12.500 EUR/mese aggiuntivi a regime.

PARTE 7 — Knowledge Base a Grafo: Si o No?

Perche un grafo (e non solo vettori)

I vettori (embedding + ricerca semantica) funzionano bene per:

- "Trova documenti simili a questa domanda"
- Ricerca per significato in documenti non strutturati

Il grafo aggiunge:

- Relazioni esplicite: "Questo prodotto e venduto da questo reparto che e gestito da questa persona"
- Ragionamento multi-hop: "Chi e responsabile del processo che genera questo report?"
- Contesto strutturato: organigrammi, processi, dipendenze, workflow

Quando serve il grafo

Caso d'uso | Solo vettori | Vettori + Grafo

FAQ/documentazione | Sufficiente | Overkill

Processi aziendali con ruoli | Limitato | Necessario

Relazioni clienti/prodotti/persone | Limitato | Necessario

Troubleshooting con dipendenze | Limitato | Necessario

Onboarding nuovi dipendenti | Sufficiente | Migliore

Decisione implementata (ADR-001)

Architettura ibrida Neo4j 5 Community + Qdrant:

- Qdrant per vector search (embedding 1536d, HNSW, filtering avanzato, quantization)
- Neo4j per graph traversal (Cypher, entity relations, professional knowledge graph)
- Fusion layer combina entrambi i contesti nel prompt LLM

Perche non Memgraph: Cypher incompleto (~80%), richiede 4-6GB RAM per dataset medio, ecosystem piccolo, no full-text index nativo.

Perche non solo Neo4j vector (v5.11+): no HNSW tuning, no quantization, no hybrid scoring, ordini di grandezza piu lento di Qdrant su >100K vettori.

Perche non solo Qdrant: impossibile modellare relazioni (ENABLES, CONTRADICTS, MITIGATES), nessun reasoning chain, knowledge graph professionale perde struttura.

Il pattern GraphRAG (entity extraction + graph traversal + vector search) e implementato nativamente nella piattaforma (Phase 4). Vedi [aia-platform/docs/ADR-001-neo4j-graph-vector.md](#) per analisi comparativa completa.

PARTE 8 — Client: Opinione Tecnica Approfondita

Opzione A: Solo Web App (PWA)

PRO:

- + Zero installazione
- + Aggiornamenti istantanei (deploy = tutti aggiornati)
- + Funziona su mobile/tablet/PC
- + Manutenzione minima (un solo codebase)
- + Tempo di sviluppo: 3-4 settimane per MVP

CONTRO:

- No accesso file system locale (senza agent)
- No interazione diretta con app desktop
- Limitato su notifiche push (dipende da OS)
- Percepito come "meno serio" di un'app installata (bias psicologico)

Opzione B: App Desktop (Tauri/Electron)

PRO:

- + Accesso completo a file system
- + Può lanciare processi, leggere email locali
- + Tray icon, hotkey globali, always-on
- + Percepito come "prodotto vero"
- + Offline mode possibile (con Ollama locale)

CONTRO:

- Doppia manutenzione (web + desktop)
- Installazione richiesta (barrier)
- Aggiornamenti da gestire (auto-updater)
- Cross-platform (Win + Mac) = più lavoro
- Tempo di sviluppo: 6-8 settimane per MVP

Opzione C: Web App + Micro-Agent locale [RACCOMANDATA]

PRO:

- + Chat/KB/agenti via web (zero installazione per quelli)
- + Micro-agent locale (20MB, tray icon) solo per azioni OS
- + Il micro-agent espone un server MCP locale che la web app chiama
- + Separa le responsabilità: UI online, azioni offline
- + Aggiornamenti UI istantanei, agent locale aggiornato raramente
- + Può partire SENZA agent locale e aggiungerlo dopo

CONTRO:

- Due codebase (web + agent), ma agent è piccolo e stabile
- L'utente deve installare l'agent per funzionalità avanzate

Perché Opzione C: parti con la web app (settimane 1-4), la rendi funzionale per chat/KB/agenti. Quando un cliente chiede "ma puoi leggere i miei file Excel?" -> sviluppi il micro-agent. Non prima.

Il micro-agent in Tauri (Rust + webview) pesa ~5MB e può:

- Monitorare cartelle locali (nuovi file -> ingest in KB)
- Leggere/scrivere file su richiesta dell'agente (con conferma utente)
- Inviare email via client locale (Outlook COM, Thunderbird)
- Aprire URL nel browser
- Eseguire script/comandi (con conferma)

PARTE 9 — Interazione Autonoma vs Conferma

Modello a 3 livelli

Livello | Azione | Conferma? | Esempio

Read-only	Leggere file, cercare in KB, consultare email	Mai	"Cerca nel CRM il cliente X"
Low-risk write	Creare bozza email, generare report, annotare	Opzionale (configurabile)	"Prepara la risposta a questa email"
High-risk action	Inviare email, modificare file, pubblicare	Sempre	"Invia questa email al cliente"

L'utente (o il consulente in fase di setup) configura per ogni agente quali azioni richiedono conferma. Default: tutto in conferma tranne read-only.

UX suggerita:

- L'agente propone l'azione in chat: "Vorrei inviare questa email a mario@cliente.it. [Approva] [Modifica] [Rifiuta]"
- Per azioni batch: "Ho trovato 5 fatture da classificare. [Mostra anteprima] [Esegui tutte] [Una alla volta]"

PARTE 10 — Nome, Posizionamento, Integrazione con Portfolio

Come si integra nel tuo portfolio esistente

PORTFOLIO ATTUALE	PIATTAFORMA
=====	=====
AI Quick Start (1.500-3.500 EUR)	Include: setup piattaforma base
	+ 2-3 agenti
v	+ KB iniziale
AI Strategico (4.000-15.000 EUR)	Include: piattaforma completa
	+ 5-7 agenti
v	+ integrazioni
CAIO-aaS (1.500-4.000 EUR/mese)	Include: piattaforma + governance
	+ evoluzione continua
	+ nuovi agenti/mese

La piattaforma diventa il deliverable tangibile che il cliente riceve. Non piu "ti ho fatto consulenza e ti lascio un PDF". Ma "ti lascio un SISTEMA funzionante che continua a produrre valore anche dopo che me ne vado".

Naming (suggerimenti)

Nome	Pro	Contro
MindForge	Evocativo, "forgiare la mente aziendale"	Forse troppo generico
CortexAI	Tecnico ma comprensibile	Tanti "Cortex" in giro
FlowMind	Flow = flusso di lavoro + mente	Carino
AziendAI	Italianissimo, chiaro	Limita a mercato italiano
OracleDesk	Oracle = sapienza + Desk = scrivania	Oracle e un trademark
NeuronDesk	Neurone + desk (assistente)	Tecnico

Nota: il nome non e urgente per il MVP. Scegli dopo aver validato.

PARTE 11 — Checklist Decisioni da Prendere

Prima di iniziare lo sviluppo, conferma:

- ☐ Primo cliente pilota: chi e? quale settore? quale problema specifico?
- ☐ Linguaggio backend: TypeScript (piu veloce per te?) o Python (piu ecosistema AI)?
- ☐ Base platform: Dify (piu completo) o build custom su LangGraph (piu controllo)?
- ☐ Client base: OpenWebUI fork o custom React/Next.js?
- ☐ Hosting iniziale: Hetzner (EU, economico) o DigitalOcean (piu semplice)?
- ☐ Modelli default: Quale mix? Suggerisco: DeepSeek per routine, Claude per complesso
- ☐ Grafo KB: subito (settimana 1) o solo vettori e poi aggiungi (mese 3)?
- ☐ Branding: nome provvisorio per il MVP?
- ☐ Pricing primo cliente: quanto chiedi per il pilota? (Suggerisco: 50% sconto in cambio di case study)

PARTE 12 — Prossimi Passi Concreti

Questa settimana

- Installa e testa Dify self-hosted su un VPS di test (o Docker locale)
- Installa OpenWebUI e collegalo a LiteLLM con 2-3 modelli
- Carica una KB di test (documenti di una PMI che conosci) e testa il RAG
- Identifica 1 cliente pilota dal tuo network

Prossime 2 settimane

- Fai una demo live al cliente pilota (anche se grezza)
- Definisci 3 agenti specifici per il suo caso d'uso
- Valida il pricing: "Pagheresti 300 EUR/mese per questo?"

Mese 1

- Costruisci il MVP con l'approccio scelto
- Deploy per il primo cliente con monitoraggio attivo
- Documenta tutto: sara la base per il secondo cliente

TOKEN & COSTO STIMATO

Voce Valore	
Lunghezza documento	~550 righe
Token input stimati	~15.000 (contesto + documenti letti)
Token output stimati	~8.000
Modello	Claude (Bedrock)
Costo output stimato	~\$0.60
Costo totale sessione	~\$0.85

v1.0 — 2026-06-07 — Studio esplorativo iniziale. Da aggiornare dopo validazione con primo cliente.