

Piano Esecutivo: Piattaforma AI Assistente Aziendale (AIA)

****Versione**:** 1.0 — 7 giugno 2026 ****Autore**:** Elios Scoglio ****Stato**:** In esecuzione (Fase 0-3 completate, Fase 3.5 in corso)

Executive Summary

Piattaforma AI multi-tenant per PMI italiane. Il consulente gestisce N clienti da una dashboard centrale, ciascuno con agenti AI personalizzati, knowledge base aziendale, e integrazioni operative (email, file, calendario). Due modelli di vendita: progetto chiuso (A CORPO) e retainer continuativo (A FACTORY).

Budget infrastruttura: ~50 EUR/mese (Hetzner CX41)
Break-even stimato: 3 clienti FACTORY o 2 progetti A CORPO
Timeline sviluppo: ~10 settimane part-time

Struttura Progetto

```
Vision/aia-platform/
├── docker-compose.yml      # Stack produzione (Traefik, PG, Redis, Qdrant, LiteLLM)
├── docker-compose.dev.yml  # Override dev (porte esposte, no SSL)
├── .env.example            # Variabili ambiente documentate
├── Makefile                # 25+ target operativi
├── CLAUDE.md               # Istruzioni per AI coding assistant
├── infrastructure/
│   ├── traefik/            # Reverse proxy + SSL Let's Encrypt
│   ├── postgres/init/     # Extensions (pgvector, pg_trgm) + schema multi-tenant
│   ├── redis/             # AOF persistence, 512MB LRU
│   ├── qdrant/            # Vector DB config
│   ├── litellm/config.yaml # 3 tier modelli (DeepSeek/Haiku/Sonnet)
│   └── backups/           # Script backup automatico
├── packages/
│   ├── shared/            # Types, Result pattern, AppError, costanti
│   └── ai-client/         # LiteLLM client wrapper con retry/backoff
├── apps/
│   ├── gateway/           # Hono API (22 file) — il cervello
│   ├── dashboard/        # React SPA consulente (Fase 2)
│   ├── client/            # React PWA utente finale (37 file)
│   └── local-agent/       # Micro-agent OS (Fase 3)
├── templates/             # Agent templates YAML
├── scripts/               # Setup VPS, deploy, seed, migrate
└── docs/                  # Manuali per fase
```

Stack Tecnologico

Layer	Tecnologia	Motivo
API Framework	Hono	10x Express, TypeScript-native, Bun-ready
ORM	Drizzle	Type-safe, leggero, escape hatch SQL raw

Frontend | React 19 + Vite 6 + Tailwind 4 | Velocissimo, moderno
UI Components | shadcn/ui | Owned, Tailwind-native
Auth | Better Auth | Flessibile, Hono-compatible
State | Zustand + TanStack Query | Server state separato
Router | TanStack Router | Type-safe
LLM Proxy | LiteLLM (Docker) | Multi-model, cost tracking built-in
Vector DB | Qdrant (Docker) | Veloce, HNSW, filtering avanzato
Graph DB | Neo4j Community (Fase 4) | Standard de facto
Queue/Jobs | BullMQ (Redis) | Retry, concurrency, dead-letter
DB | PostgreSQL 16 + pgvector | Multi-tenant, estendibile
Hosting | Hetzner CX41 | EU, 4 vCPU, 16GB RAM, ~40 EUR/mese
Website | Astro 5 + TinaCMS + Vercel | Statico, SEO, editing online, gratis

Modello Multi-Tenancy

Componente | Strategia isolamento

PostgreSQL | Shared DB, tenant_id su ogni riga (row-level)
Qdrant | Collection kb_{tenant_id} per tenant
Redis | Prefix aia:{tenant_id}: per chiavi
Risoluzione | Header X-Tenant-ID (dashboard) o subdomain (client)

Fasi di Implementazione

FASE 0 — Infrastruttura [COMPLETATA]

- Docker Compose completo (PostgreSQL+pgvector, Redis, Qdrant, LiteLLM, Traefik)
- Schema DB multi-tenant con triggers e indici
- LiteLLM configurato con 3 tier di costo
- Script provisioning VPS Hetzner + backup automatico
- Packages condivisi (shared types, AI client)
- Manuale: docs/phase-0-infrastructure.md

Verifica: docker compose up -d && docker compose ps — tutti healthy

FASE 1 — MVP Client + Chat [COMPLETATA]

Gateway API (22 file):

- POST /api/chat — SSE streaming con RAG
- POST /api/knowledge/upload — ingest documenti asincrono (BullMQ)
- GET /api/knowledge/search — ricerca semantica Qdrant
- CRUD conversazioni, agenti, documenti
- Middleware: JWT auth, tenant resolution, RFC 7807 errors
- Service layer con Result pattern
- Chunking ricorsivo (1000 chars, 200 overlap)

Client PWA (37 file):

- Chat UI con streaming SSE in tempo reale
- Selezione agente e modello
- Upload documenti in knowledge base (drag & drop)
- Dark mode, responsive, installabile come app
- TanStack Router + Query, Zustand store

Verifica: Upload PDF → fai domanda → risposta usa contenuto del PDF

FASE 2 — Dashboard Consulente (10-14 giorni) [PROSSIMA]

Obiettivo: Gestire tutti i clienti da remoto.

Pagina	Funzione
/ Overview	Grid tenant cards (nome, agenti attivi, costo mese, ultima attivita)
/tenants/:id	Dettaglio tenant con tabs
/tenants/:id/agents	Editor agenti: system prompt, model, KB bindings, test inline
/tenants/:id/kb	Upload docs, status, ricerca semantica, re-index
/tenants/:id/usage	Grafici costo per modello/giorno, budget alert
/tenants/:id/conversations	Browser conversazioni (read-only), export
/onboarding	Wizard 6 step per nuovo cliente
/billing	Breakdown costi cross-tenant, export CSV
/marketplace	Libreria template agenti
/settings	Config piattaforma, chiavi LLM, backup

Flusso onboarding nuovo cliente:

- Wizard → info azienda, settore, dimensione
- Seleziona use case → auto-suggerisce agenti template
- Sistema crea: tenant DB, collection Qdrant, utenti invitati
- Upload documenti iniziali (o crawl URL sito)
- Configura agenti (pre-compilati, modificabili)
- Attiva → cliente riceve email con link PWA

FASE 3 — Integrazioni (7-10 giorni)

- Email: IMAP (Aruba, Register) + Microsoft Graph (M365)
- Browser automation: Playwright (scraping, azioni web)
- Local micro-agent: Node + WebSocket, file system sandboxed, system tray
- 3 livelli rischio azioni: read-only / low-risk / high-risk (con conferma)
- Dashboard: config OAuth, IMAP, test connessione

FASE 3.5 — Desktop Bridge (7-10 giorni) [IN CORSO]

Obiettivo: L'agente locale puo leggere e interagire con tutte le finestre aperte sul computer del cliente (come Claude Desktop / ChatGPT Desktop, ma con knowledge base aziendale e approvazione remota).

Architettura Hybrid:

- Layer 1 (Accessibility API): legge UI tree nativo (UIA su Windows, AX su Mac)
- Layer 2 (Vision): screenshot + LLM multimodale come fallback

- Layer 3 (Input): keyboard/mouse simulation via nut-tree

Componenti creati:

- packages/desktop-bridge/ — Pacchetto cross-platform (Windows first, Mac ready)
- Window enumeration (Win32 EnumWindows via koffi FFI)
- UI tree reading (PowerShell + System.Windows.Automation)
- Screenshot per-window (screenshot-desktop + sharp)
- OCR fallback (Tesseract.js)
- Vision analysis (LLM via @aia/ai-client)
- Input simulation (nut-tree)
- Safety layer: risk classification + window guard + pre/post screenshot
- apps/local-agent/src/capabilities/desktop.ts — 12 nuove azioni desktop
- apps/dashboard/src/components/desktop/ — UI approvazione + monitor live

Modello sicurezza a 3 livelli:

Rischio Azioni Approvazione		
read-only	listWindows, readWindow, screenshot, analyzeScreen, getUITree	Auto
low-risk	focusWindow, scrollWindow, clipboard read	Auto + log
high-risk	typeText, clickElement, pressHotkey, mouseClick	Richiede conferma consulente

Differenziatore vs Claude/ChatGPT Desktop:

- Consulente approva da remoto (non serve utente davanti allo schermo)
- Agente conosce il contesto aziendale (RAG + graph KB)
- Azioni persistite e auditabili
- Funziona in background (agent always-on)

Verifica: Agent connesso → listWindows → screenshot finestra → analyzeScreen → risposta contestuale

FASE 4 — Knowledge Base a Grafo (5-7 giorni)

- Neo4j Community in docker-compose
- Entity extraction pipeline (LLM estrae entita durante ingest)
- Graph-enhanced RAG (Qdrant + Neo4j in parallelo, risultati fusi)
- Dashboard: visualizzazione grafo per tenant

FASE 5 — Funzionalita SaaS (7-10 giorni)

- Subscription plans con limiti (conversazioni/mese, KB size, modelli)
- Stripe o fatturazione manuale per PMI italiane
- Agent marketplace (template gallery, install, rating)
- Self-service signup (opzionale, per fase franchising)
- Weekly report automatico (PDF) per consulente

FASE 6 — Documenti Commerciali [COMPLETATA]

File Status Righe		
AIA-Playbook-Piattaforma.md	Completato	~1450
AIA-Manuale-Piattaforma.md	Completato	~1057

AIA-Sito-Piattaforma.md | Completato | ~800

STUDY-AIA-Piattaforma.md | In completamento | ~1300

FASE 7 — Sito Web Promozionale [IN CORSO]

Stack: Astro 5 + TinaCMS + Vercel (costo: 0 EUR/mese)

Pagine:

- Home (hero + grid 9 servizi + stats + testimonial + CTA)
- 9 landing page servizi (AI Platform, AI Adoption, FCTO, DIGI, ARCH, LEAD, AGILE, WELL, PA)
- Chi sono, Risorse (lead magnet), Contatti (form + Calendly), Blog

Componenti: Header, Footer, Hero, ServiceCard, FeatureGrid, PricingTable, Testimonial, CTASection, ContactForm, CalendlyEmbed, BlogCard, LeadMagnetCard

Lead generation: form → Resend webhook, download manuali gated, Calendly per discovery call, Plausible analytics

FASE 8 — Client macOS (10-14 giorni) [PIANIFICATA]

Obiettivo: Portare il local-agent + desktop-bridge su macOS con supporto nativo.

Componenti:

- packages/desktop-bridge/src/providers/macos.ts — Provider nativo macOS:
 - Accessibility API via @aspect-build/accessibility o subprocess osascript
 - AppleScript per interazione con app native (Mail, Finder, Safari, Calendar)
 - CoreGraphics screen capture (via screencapture CLI o Swift companion)
 - CGEvent per input simulation (keyboard/mouse)
- apps/local-agent-macos/ — Electron app per macOS con:
 - Menu bar icon (equivalente system tray)
 - Accessibility permission request UI (System Preferences → Privacy)
 - Auto-update via Sparkle
 - DMG installer con notarization Apple
 - Sandboxing: entitlements per screen recording + accessibility + file access

Sfide macOS specifiche:

Sfida | Soluzione

Accessibility permission obbligatoria | First-run wizard che guida l'utente in System Preferences

Screen Recording permission separata | Richiesta solo se vision/screenshot abilitati

Apple notarization per distribuzione | Signing con Developer ID + notarytool

App-specific automation (es. Mail.app) | AppleScript bridge per app Apple native

Electron security restrictions | nodeIntegration solo in preload, context isolation

Stack:

- Electron 30+ (cross-platform shell)
- @aspect-build/accessibility o subprocess swift companion per AX API
- osascript per AppleScript (automazione app Apple)
- screencapture CLI per screenshot (evita dipendenze native)
- Sparkle per auto-update
- electron-builder per DMG/PKG

Verifica: Install su Mac → permission granted → listWindows → read Safari tab content → screenshot → analyzeScreen

Modello di Business

A CORPO (progetto chiuso)

Elemento	Dettaglio
Cosa include	Audit processi + KB + agenti + integrazioni + training
Timeline	4-8 settimane
Pricing	5.000-15.000 EUR
Post-progetto	Hosting + manutenzione: 300-800 EUR/mese
Target	PMI che vogliono prodotto finito, budget definito

A FACTORY (retainer continuo)

Elemento	Dettaglio
Cosa include	Piattaforma + governance + evoluzione mensile
Cadenza	Retainer mensile continuo
Pricing	1.500-4.000 EUR/mese
Include	Nuovi agenti, KB update, integrazioni, report ROI
Target	Medie imprese, partner AI continuativo

Unit Economics

Voce	Costo/mese per tenant
Infra (quota)	~5-10 EUR
Token LLM (media)	~20-80 EUR
Supporto (tempo)	~2-4 ore
Totale costo	~50-150 EUR
Revenue FACTORY	1.500-4.000 EUR
Margine	~90%

Break-even: 3 clienti FACTORY coprono costi fissi + margine

Timeline con Parallelismo

- Settimana 1-2: [FATTO]
Fase 0 (infra) + Fase 6 (documenti) + inizio Fase 1
- Settimana 2-3: [FATTO]
Fase 1 (gateway + client PWA) + Fase 7 (sito web)
- Settimana 3-5: [FATTO]
Fase 2 (dashboard consulente)
- Settimana 5-7: [FATTO]
Fase 3 (integrazioni email/browser/local agent)
- Settimana 7-8: [IN CORSO]
Fase 3.5 (desktop bridge — Windows)
- Settimana 8-9:
Fase 4 (graph KB + Neo4j)
- Settimana 9-11:
Fase 5 (SaaS features + marketplace)
- Settimana 11-13:
Fase 8 (client macOS — Electron + native AX)

Risorse Riutilizzabili (dal progetto MCP esistente)

File sorgente	Riutilizzo per
AI/Germania/mcp/services/msgraph/mail.ts	Integrazione email M365
AI/Germania/mcp/services/msgraph/calendar.ts	Integrazione calendario
AI/Germania/mcp/services/msgraph/auth.ts	OAuth MSAL flow
AI/Germania/mcp/services/xenon-knowledge/tools.ts	Pattern CRUD knowledge
AI/Germania/mcp/services/memgraph/tools.ts	Pattern query graph DB (migrato a Neo4j + Cypher)

Criteri di Successo

Fase	Criterio "done"
Fase 0	docker compose ps — tutti i container healthy
Fase 1	Upload PDF → domanda → risposta con contenuto PDF
Fase 2	Login dashboard → crea tenant → configura agente → client lo vede
Fase 3	Configura email → agente legge inbox → propone risposta
Fase 3.5	Agente connesso → listWindows → screenshot finestra → analyzeScreen → risposta contestuale
Fase 4	Documenti con entità correlate → grafo migliora risposte
Fase 5	Secondo tenant → isolamento OK → tracking costi funziona
Fase 6	4 documenti commerciali completi (>800 righe ciascuno)
Fase 7	Sito live su Vercel, modificabile da TinaCMS
Fase 8	Install su Mac → permission granted → listWindows → read Safari tab → screenshot → analyzeScreen

Branding & Marketing

Identità aziendale

L'azienda e il prodotto si chiamano 108 Vision AI. Il numero 108 è sacro in molteplici tradizioni (buddhismo, induismo, arti marziali, astronomia) e rappresenta completezza, connessione e trasformazione. "Vision" comunica la capacità di vedere il futuro tecnologico dei clienti e progettarlo oggi. "AI" posiziona immediatamente nel dominio dell'intelligenza artificiale. Il team include competenze in architettura software, AI engineering, leadership tecnica e consulenza strategica.

Brand architecture:

- 108 Vision AI = nome azienda (il team, la consulenza, il partner)
- 108 Vision AI = anche il prodotto/piattaforma (brand unificato — semplifica comunicazione)
- Abbreviazione informale: "108" o "Vision AI"

Tono comunicativo: "noi", "il nostro team", "la nostra visione" — mai prima persona singolare. Posizionamento: partner tecnologico di fiducia, non freelancer. Esempio: "In 108 Vision AI aiutiamo le PMI a..." non "Aiuto le PMI a..."

Proposte nome azienda: 108 + estensione

Proposta | Significato | Dominio suggerito | Note

108 Labs	Laboratorio di innovazione — R&D applicata, sperimentazione	108labs.it	Moderno, tech, evoca Silicon Valley senza essere derivativ
108 Vision	Visione chiara del futuro tecnologico	108vision.it	Direttamente legato alla cartella Vision del portfolio
108 Digital	Trasformazione digitale come core	108digital.it	Ampio, riconoscibile, ma forse generico
108 Minds	Menti al lavoro — intelligenza collettiva (umana + AI)	108minds.it	Forte legame con AI, evoca pensiero e strategia
108 Forward	Andare avanti, progresso, next step	108forward.it	Dinamico, orientato al futuro
108 Studio	Atelier di consulenza premium, artigianato tech	108studio.it	Posizionamento alto, boutique
108 Nexus	Punto di connessione tra business e tecnologia	108nexus.it	Potente, ma forse troppo corporate
108 Arc	Arco = architettura + percorso (arc of transformation)	108arc.it	Elegante, breve, evoca costruzione

Decisione: 108 Vision AI — brand unificato azienda+prodotto. Combina il numero sacro (completezza, trasformazione), la visione strategica e l'AI come core competence. Funziona sia come nome azienda ("108 Vision AI") sia come prodotto che il cliente usa. Dominio target: 108visionai.it / 108vision.ai (verificare disponibilità).

Proposte marchio prodotto: Piattaforma AI per PMI

Il prodotto (la piattaforma) ha bisogno di un nome proprio, separato dall'azienda. L'azienda (108 X) è il fornitore; il prodotto è quello che il cliente usa ogni giorno.

Nome prodotto | Claim | Registro | Note

Menti	"L'intelligenza che la tua azienda merita"	Caldo, italiano, accessibile	Richiama "mente" (AI) + "menti" (team), facile da ricordare
Prisma	"Ogni angolo del tuo business, illuminato"	Elegante, sfaccettato	Evoca chiarezza, multi-prospettiva, analisi
Atlante	"La mappa intelligente della tua azienda"	Solido, autorevole	Knowledge base = atlante di conoscenza aziendale
Synapse	"Connetti sapere e azione"	Tech, internazionale	Connessione neurale = AI che collega info a decisioni
Lumina	"Luce sui tuoi processi"	Luminoso, femminile, premium	AI che illumina, chiarisce, rende visibile l'invisibile
Nodi	"Dove la conoscenza si incontra"	Minimale, italiano	Grafo, connessioni, knowledge base = nodi
Onda	"L'AI che muove la tua azienda"	Dinamico, italiano	Movimento, propagazione, trasformazione progressiva
Copernico	"Una nuova prospettiva per il tuo business"	Autorevolezza, rivoluzione	Cambio di paradigma, come la rivoluzione copernicana

108 AI | "Intelligenza artificiale, competenza reale" | Diretto, brand-linked | Semplice, lega prodotto e azienda
Tessera | "Ogni pezzo al suo posto" | Costruzione, completezza | Mosaico di conoscenza, ogni documento e una tessera

Claim principali (indipendenti dal nome prodotto)

Per la piattaforma AI:

Claim	Target	Registro
"L'AI che capisce la tua azienda"	PMI generalista	Chiaro, benefit-oriented
"Il tuo team invisibile, sempre operativo"	PMI con poche risorse	Emotivo, evoca supporto costante
"Intelligenza artificiale, competenza reale"	PMI scettica verso AI	Rassicurante, bilancia tech e human
"Dal documento alla decisione, in secondi"	Manager operativi	Specifico, orientato all'efficienza
"L'AI su misura. Non un chatbot qualsiasi."	PMI che ha provato ChatGPT	Differenziante, posizionamento premium
"Conosce i tuoi processi. Risponde come un collega."	Dipendenti end-user	Familiare, bassa barriera d'ingresso
"Meno tempo a cercare. Più tempo a decidere."	C-level / imprenditori	ROI implicito, dolore reale
"La memoria della tua azienda, potenziata dall'AI"	Aziende con knowledge loss	Evoca continuità, anti-turnover

Per l'azienda 108:

Claim	Posizionamento
"Tecnologia che trasforma. Persone che accompagnano."	Partnership umana + tech
"Dal codice alla strategia. Un team, ogni risposta."	Full-stack consulting
"108 modi di far crescere il tuo business."	Gioco sul numero, ampiezza servizi
"Architettura, AI, leadership. Un partner, zero complessità."	Semplificazione per il cliente
"Il futuro tech della tua azienda, progettato oggi."	Vision + concretezza
"Non vendiamo tecnologia. Costruiamo capacità."	Differenziazione da vendor/software house

Strategia Marketing (primi 90 giorni)

Settimana 1-4: Fondamenta

Azione	Canale	Obiettivo
Sito live su Vercel con tutte le landing	Web	Presenza professionale, SEO
Profilo LinkedIn aziendale "108 [X]"	LinkedIn	Autorevolezza, contenuti
3 manuali PDF come lead magnet	Web + LinkedIn	Raccolta email, posizionamento
12 post LinkedIn programmati (dal Content Calendar)	LinkedIn	Visibilità organica
Google Business Profile	Google	Local SEO (se rilevante)

Settimana 5-8: Trazione

Azione	Canale	Obiettivo
Webinar gratuito "AI per PMI: da dove partire"	Zoom + LinkedIn Event	Lead generation qualificata
3 case study (anche simulati/anonimi) pubblicati	Blog sito	Social proof
Outreach diretto a 50 PMI target (email + LinkedIn)	Direct	Pipeline commerciale
Partnership con 2-3 commercialisti/consulenti lavoro	Referral	Canale inbound indiretto
Newsletter settimanale (Brevo/Resend)	Email	Nurturing

Settimana 9-12: Conversione

Azione | Canale | Obiettivo

Discovery call gratuite (target: 10) | Calendly | Conversione prospect

Prima proposta A CORPO inviata | Direct | Revenue

Primo cliente FACTORY attivato | Direct | Revenue ricorrente

Testimonial video dal primo cliente | LinkedIn + sito | Social proof reale

Iterazione landing page basata su dati | Web | Ottimizzazione conversione

Budget marketing primi 90 giorni: 0-500 EUR (LinkedIn ads opzionali, tutto il resto organico)

KPI da tracciare:

- Visite sito / settimana
- Lead (email raccolte) / settimana
- Discovery call prenotate / mese
- Proposte inviate / mese
- Conversion rate proposta → cliente
- Revenue MRR (Monthly Recurring Revenue)

Prossimi Passi Immediati

- [x] Completare STUDY-AIA-Piattaforma.md
- [x] Completare sito web Astro
- [x] Aggiornare PORTFOLIO-INDEX.md con track AIA
- [] Scegliere nome azienda (108 + X) e nome prodotto
- [] Registrare dominio e creare profilo LinkedIn aziendale
- [] Iniziare Fase 2: Dashboard consulente
- [] Primo deploy su VPS Hetzner per test end-to-end
- [] Preparare 3 case study per il sito