

Principi di AI Engineering & Governance

Guida operativa per chi usa AI come strumento di lavoro quotidiano — non come giocattolo, non come oracolo.

>

Questo documento e' pensato per essere condiviso con il team come fondamento di cultura AI.

>

****Ultimo aggiornamento:** 2026-06-14 ****Autore:** Elios Scoglio + Space Copilot ****Destinazione:** Team dev +****
condivisione su Confluence e Knowledge Graph**

1. Il Problema del Context Window

Cos'e' il context window e perche' e' il vincolo principale

Il context window e' la "memoria di lavoro" di un LLM: tutto cio' che il modello puo' vedere in un singolo turno di conversazione. Non e' memoria persistente — e' un buffer che si riempie e, una volta pieno, forza il sistema a comprimere o scartare informazioni.

Modello	Context window	Equivalente pratico
Claude Sonnet 4.6	200K token	~150K parole / ~500 pagine
Claude Opus 4.8	200K token	Idem, ma piu' lento e costoso
GPT-4o	128K token	~100K parole
DeepSeek V3	128K token	~100K parole

I 7 problemi concreti

1. Degradazione con la distanza ("Lost in the Middle")

L'informazione all'inizio e alla fine del context viene elaborata meglio di quella nel mezzo. Un'istruzione critica a pagina 3 di un prompt lungo 50 pagine ha probabilita' significativa di essere ignorata o "diluata".

Implicazione pratica: le regole piu' importanti vanno in cima (CLAUDE.md) o in fondo (ultime istruzioni). Mai nel mezzo di un muro di testo.

2. Costo proporzionale

Ogni token in input viene elaborato ad ogni turno. Un context di 100K token costa ~10x un context di 10K token — per la stessa domanda. Conversazioni lunghe = costi che esplodono senza che te ne accorgi.

3. Illusione di comprensione

Il modello non "legge" il context come un umano. Lo processa statisticamente. Piu' rumore c'e', piu' il segnale si perde. Aggiungere "tutto il codice" non aiuta — spesso peggiora perche' il modello correla cose irrilevanti.

4. Context stuffing = antipattern

Caricare tutto sperando che il modello "capisca" e' l'errore piu' comune dei principianti. Il modello non capisce — correla. Se il contesto e' rumoroso, le correlazioni saranno rumorose. Meno rumore = risposte migliori.

5. Nessuna persistenza nativa

Alla fine della conversazione, tutto scompare. Senza sistemi esterni (memory, knowledge graph, file), ogni sessione riparte da zero. L'AI non "ricorda" — simula continuita' solo all'interno della stessa finestra.


6. Compressione automatica

Quando il context si avvicina al limite, il sistema comprime i messaggi precedenti. Questa compressione perde dettagli. Decisioni prese 30 messaggi fa possono essere "dimenticate" o distorte nella compressione.

7. Conflitto di istruzioni

Piu' cose carichi nel context, piu' probabilita' ci sono che due istruzioni si contraddicano. Il modello non ti avvisa — sceglie silenziosamente quale seguire, spesso in modo non deterministico.

Come si gestisce la dimensione



Regole operative

Regola	Perche'
Dare solo cio' che serve	Meno rumore = risposte migliori + meno costo
Istruzioni critiche in cima	"Lost in the middle" — cima e fondo sono zone di massima attenzione
Separare permanente da volatile	CLAUDE.md per il "sempre"; conversazione per il "adesso"
Usare reference, non contenuto	"Leggi il file X" > "ecco 500 righe incollate"
Comprimere proattivamente	Riassumere decisioni prese, non ripetere tutto il ragionamento
Sessioni brevi e mirate	Una sessione = un obiettivo. Non conversazioni infinite
Ripartire puliti quando il context e' sporco	Se l'AI inizia a dare risposte strane, nuova sessione


2. Adattare l'AI alla Persona e all'Azienda

Il problema: ogni AI nasce generica

Un LLM appena deployato non sa nulla di:

- Chi sei (ruolo, seniority, responsabilita', modo di lavorare)
- Come lavori (preferenze, stile comunicativo, velocita' decisionale)
- Cosa conta nel tuo contesto (vincoli aziendali, compliance, stack tecnico)
- Cosa hai gia' deciso (ADR, pattern consolidati, errori passati da non ripetere)
- Cosa ti aspetti da lui (che sfide, che spieghi, che chieda, che sia sintetico?)

La soluzione: stratificazione della conoscenza



Come si costruisce (passo per passo)

Fase 1: Identita' (giorno 1)

Scrivi un CLAUDE.md che risponda a:

- Chi sei? (ruolo, seniority, dominio)
- Come vuoi che ti parli? (sintetico? che spieghi? che sfide?)
- Quali sono i vincoli non negoziabili? (sicurezza, compliance, processo)
- Come deve comportarsi l'AI? (chiedere prima di agire? spiegare sempre?)

Fase 2: Contesto aziendale (settimana 1)

- Carica l'architettura su knowledge graph per query semantiche
- Documenta i vincoli di compliance, sicurezza, processo
- Mappa le integrazioni critiche e i rischi noti
- Scrivi gli ADR delle decisioni gia' prese

Fase 3: Feedback loop (continuo)

Ogni volta che l'AI sbaglia o fa bene, salva un feedback:

- "Non fare push automatico" → regola permanente
- "Spiega sempre cosa fai e perche'" → regola permanente
- "Usa Sonnet per gli agenti, non Opus" → regola permanente

Questi feedback diventano le "regole apprese" — l'AI migliora sessione dopo sessione.

Fase 4: Evoluzione (mese 1+)

Il sistema impara:

- I tuoi pattern decisionali
- Quando chiedere e quando procedere
- I tuoi colleghi, i flussi, le scadenze
- Le trappole specifiche del tuo dominio

Diventa un "copilot" reale — non un chatbot generico.

Indicatori di maturita'

Livello	Segnale	Tempo tipico
Principiante	Devi ripetere le stesse istruzioni ogni sessione	Giorno 1
Intermedio	L'AI ricorda chi sei e i vincoli principali	Settimana 1
Avanzato	L'AI anticipa problemi che tu non hai ancora visto	Mese 1
Esperto	L'AI sfida le tue assunzioni e propone alternative migliori	Mese 2+

3. Strategie di Risparmio Token

Perche' conta

I token sono il "carburante" dell'AI. Ogni token ha:

- Costo diretto (API billing)
- Costo indiretto (tempo di elaborazione, degradazione qualita')
- Costo nascosto (conversazione lunga = piu' errori = piu' rework = piu' token)

Risparmiare token non e' solo economia — e' qualita': meno rumore nel context = risposte migliori.

Strategia 1: Model Routing (il 90% del risparmio)

Task	Modello	Costo relativo
Decisione architetturale	Opus	\$\$\$
Code review complesso	Opus	\$\$\$
Analisi impatto cross-system	Opus	\$\$\$
Implementazione	Sonnet	\$
Ricerca/esplorazione	Sonnet	\$
Refactoring guidato	Sonnet	\$
Formatting/template	Haiku	¢
Classificazione/triage	Haiku	¢
Generazione boilerplate	Haiku	¢

Regola pratica: Sonnet per il 90% del lavoro. Opus solo per decisioni dove sbagliare costa caro. Haiku per bulk/automazione.

Impatto: usare Sonnet al posto di Opus = 70-80% risparmio a parita' di output per la maggior parte dei task.

Strategia 2: Prompt concisi e strutturati

```
// MALE (56 token, vago, forza l'AI a indovinare):
"Puoi per favore guardare questo codice e dirmi se ci sono
problemi di qualsiasi tipo che dovrei considerare?"

// BENE (22 token, preciso, l'AI sa esattamente cosa fare):
"Review OrderService.cs:45-80. Focus: race condition nel lock posti.
Verifica thread safety e idempotenza."
```

Regole:

- Specifica il file e le righe
- Dici cosa cercare (non "problemi generici")
- Dici il formato output che vuoi
- Niente convenevoli ("Puoi per favore...")

Strategia 3: Context pruning aggressivo

- Non ricaricare file già letti se non sono cambiati
- Usare offset e limit per leggere solo le righe rilevanti
- Preferire grep mirato a read dell'intero file
- In conversazioni lunghe: riassumere le decisioni e ricominciare puliti
- Mai incollare codice nel prompt — fai leggere il file all'AI

Strategia 4: Caching tramite configurazione

- CLAUDE.md = istruzioni cachate (caricate una volta, usate sempre, mai ripetute)
- Knowledge graph = context on-demand (caricato solo quando serve)
- Memory file = stato persistente senza ripetere ogni sessione

Strategia 5: Agenti paralleli leggeri

- Agenti Sonnet per ricerca parallela (5x meno costosi di Opus)
- Ogni agente ha un task specifico e ristretto (meno context = meno costo)
- L'orchestratore sintetizza i risultati — non rifa il lavoro

Strategia 6: Sessioni corte e mirate

```
MALE: Una sessione di 4 ore con 200 messaggi su 15 topic diversi
→ Context degradato, costo altissimo, errori in crescita

BENE: 5 sessioni da 20 minuti, ognuna con un obiettivo chiaro
→ Context pulito ogni volta, risposte precise, costo controllato
```

Impatto economico reale

Strategia | Risparmio stimato | Difficoltà

Model routing (Sonnet vs Opus) | 70-80% | Bassa
 Prompt concisi | 30-50% | Media
 Context pruning | 40-60% | Media
 Sessioni corte | 30-40% | Bassa
 Agenti paralleli Sonnet | 50-70% vs singolo Opus | Alta (setup)
 Caching CLAUDE.md | 20-30% per sessione | Bassa

4. Il Principio di Ownership

Definizione

L'ownership e' il principio per cui ogni decisione finale appartiene all'umano. L'AI informa, analizza, propone — ma non decide. Mai. E l'AI stessa deve saperlo, rispettarlo, e ricordartelo se necessario.

Questo non e' un principio "etico" astratto. E' un principio ingegneristico: un sistema dove nessuno possiede le decisioni produce output mediocre, incoerente e pericoloso.

Perche' e' fondamentale (e non ovvio)

L'AI ha una tendenza naturale a:

- Confermare cio' che l'utente sembra voler sentire (sycophancy)
- Procedere anche quando non ha informazioni sufficienti
- Riempire i vuoti con assunzioni plausibili ma non verificate
- Presentare incertezza come certezza (confident hallucination)
- Non fermarsi quando dovrebbe chiedere
- Non spiegare cosa sta facendo e perche' (se non gli viene imposto)

Senza ownership esplicita, l'utente scivola inconsciamente verso la delega: "l'AI ha detto cosi', quindi sara' giusto". Questo e' il failure mode piu' pericoloso.

Come si costruisce l'ownership

1. Definisci chi decide PRIMA di chiedere

SBAGLIATO: "Cosa dovremmo fare per il problema X?"

- L'AI decide, tu confermi passivamente
- Stai delegando senza accorgertene

GIUSTO: "Analizza il problema X. Dammi 3 opzioni con trade-off. Io scelgo."

- Tu decidi, l'AI informa
- L'ownership resta tua

2. Obbliga l'AI a marcare l'incertezza

Nella configurazione (CLAUDE.md), forza i marcatori:

Marcatore | Significato

- [verificato] | Fatto controllato direttamente (codice letto, documento citato)
- [probabile] | Inferenza ragionevole — pattern corrisponde ma non verifica diretta
- [non verificato] | Analogia — richiede conferma prima di agire
- [ignoto] | Non lo sa. Si deve fermare. Deve chiedere.

3. L'AI deve sapere che tu sei il decisore — e ricordartelo

L'ownership di ogni decisione e' mia.

Se mi vedi delegare passivamente, segnalalo.

Se mi vedi accettare senza critica, chiedimi: "Vuoi che lo sfidi?"

Tu non sei un esecutore silenzioso — sei un advisor che risponde a me.

L'AI non deve solo obbedire — deve attivamente proteggere la mia ownership segnalando quando sto cedendo il controllo.

4. Fai sfidare le tue stesse idee

"Prima di procedere: su quale assunzione si basa questa soluzione?
Cosa dovrebbe essere vero perche' fallisca?"

L'AI che sfida e' piu' utile dell'AI che conferma. Configurala per sfidare di default.

5. Separa analisi da azione (SEMPRE)

Fase 1: L'AI analizza (nessuna modifica al sistema)
Fase 2: Tu validi l'analisi (poni domande, sfida)
Fase 3: Solo dopo la tua approvazione esplicita, l'AI esegue

Mai le tre fasi in un unico step automatico.

6. L'AI deve spiegare SEMPRE cosa fa e perche'

Per ogni azione tecnica:
1. Spiega COSA stai per fare
2. Spiega PERCHE' lo fai (quale problema risolve)
3. Spiega cosa c'era di SBAGLIATO prima (se e' un fix/cambio)
4. Solo dopo la spiegazione, esegui

7. Mantieni il veto permanente

"Non fare push automatico."
"Non committare senza mia approvazione."
"Non procedere se non sei sicuro — chiedi."
"Non modificare piu' di 3 file senza conferma."

Queste regole non sono "rallentamenti". Sono guardrail che prevengono danni irreversibili.

Come si mantiene nel tempo

L'ownership si erode naturalmente. Piu' l'AI funziona bene, piu' la tentazione di fidarsi ciecamente cresce.

Contromisura | Frequenza | Cosa fai

Review periodica | Settimanale | Rileggi output AI con occhio critico

Spot check | 1 su 5 output | Verifica manualmente in modo approfondito

Rotation | Continua | Cambia tipo di domande per evitare pattern

Escalation rules | Definite in anticipo | Quali decisioni richiedono SEMPRE te

"Fai l'avvocato del diavolo" | Su decisioni importanti | Chiedi all'AI di argomentare CONTRO

5. Strategie per Non Perdere il Controllo

Il rischio reale

Il rischio non e' che l'AI "prenda il controllo" in senso fantascientifico. Il rischio e' l'erosione graduale del giudizio critico: accetti output senza verificarli, smetti di capire il sistema, diventi dipendente da uno strumento che non capisci.

Strategia 1: L'AI deve auto-vincolarsi

L'AI non deve solo obbedire — deve attivamente mantenere te come decisore.

Il tuo ruolo e' rendere le MIE decisioni migliori.
 Se procedi senza la mia approvazione esplicita su qualcosa di importante: e' un errore.
 Se noto che stai "decidendo per me": fermati e riformula come opzioni.
 Se mi vedi accettare passivamente: segnalalo con "Vuoi che lo sfidi prima?"

Strategia 2: Critica sistematica — mai accettare il primo output

Ciclo minimo:

- L'AI produce output
- Tu chiedi: "Cosa potrebbe essere sbagliato qui?"
- L'AI identifica i punti deboli
- Tu decidi se accettare, modificare, o rifiutare

Per decisioni importanti: usa DUE modelli diversi e confronta le divergenze.

Strategia 3: Rifare le cose N volte

"Dammi 3 approcci alternativi a questo problema.
 Per ognuno: pro, contro, rischio del peggior caso."

La prima soluzione e' quasi sempre la piu' ovvia — non necessariamente la migliore.

Strategia 4: Obbligare l'AI a dichiarare incertezza

Se non sei sicuro di qualcosa, dillo PRIMA della conclusione.
 Il silenzio sull'incertezza e' una bugia per omissione.
 Se non sai: fermati. Chiedi. Non inventare.
 Preferisco un "non lo so" onesto a una risposta plausibile sbagliata.

Strategia 5: L'AI deve fare domande PRIMA di procedere

Prima di implementare qualsiasi soluzione:

1. Dimmi quali assunzioni stai facendo
2. Dimmi cosa ti manca per essere sicuro
3. Fammi le domande necessarie per procedere informato
4. Solo dopo le mie risposte, proponi la soluzione

Questo inverte il flusso naturale dell'AI: default = "produce subito" → configurato = "chiede, poi produce".

Strategia 6: L'AI deve SPIEGARE tutto — sempre

Non eseguire azioni in silenzio. Per ogni cosa che fai:

- Cosa: descrivi l'azione
- Perche': quale problema risolve
- Alternativa: cosa avresti potuto fare diversamente
- Rischio: cosa potrebbe andare storto

Se l'AI non spiega, non puoi validare. Se non puoi validare, non hai ownership.

Strategia 7: Essere validatori, non consumatori


```

RUOLO SBAGLIATO:
"AI, fammi il codice" → copia-incolla → deploy
(Consumatore passivo — zero ownership)

RUOLO GIUSTO:
"AI, proponi una soluzione" → leggi la spiegazione
→ sfida un punto → chiedi alternative → approva
→ verifica il risultato → solo allora procedi
(Validatore attivo — ownership piena)

```

Strategia 8: Audit trail obbligatorio

- Ogni decisione importante: salva PERCHE' e' stata presa (ADR)
- Ogni output AI usato in produzione: chi l'ha validato?
- Ogni errore AI: feedback memory per non ripeterlo
- Se tra 6 mesi non sai perche' hai fatto una cosa: hai fallito

Strategia 9: Limiti di blast radius

- Non modificare piu' di 3 file alla volta senza mia conferma
- Non eseguire comandi distruttivi (delete, push, reset) mai automaticamente
- Se il cambiamento impatta piu' di un servizio: fermati e chiedi
- Non fare refactoring non richiesti
- Non aggiungere feature non richieste

Principio: piu' il potenziale danno e' alto, piu' i controlli devono essere stretti.

Strategia 10: Competenza propria come prerequisito

Non puoi validare cio' che non capisci.

L'AI non sostituisce la competenza — la amplifica. Se non capisci l'architettura, non puoi validare una proposta architeturale.

Regola: usa l'AI per andare piu' veloce dove sai gia' andare. Per esplorare territori nuovi, chiedi all'AI di INSEGNARTI, non di fare per te.

Strategia 11: L'AI deve costringere l'umano a essere il validatore

Se ti chiedo di fare qualcosa di irreversibile (deploy, push, delete, migration):

1. Ripeti cosa stai per fare in linguaggio chiaro
2. Elenca i rischi concreti
3. Chiedi conferma esplicita: "Procedo? Si/No"
4. Se non ricevi "si" chiaro: non procedere

Se ti chiedo "fai tutto tu":

- Riformula: "Posso procedere step by step, ma ti chiederò conferma a ogni fase."
- Non accettare deleghe totali su azioni irreversibili.

Strategia 12: Dead Man's Switch

Se l'AI non risponde o produce output anomalo:

- HAI un piano B che non dipende dall'AI?
- SAI fare le cose critiche manualmente?

- HAI documentazione leggibile senza AI?

La dipendenza totale e' il vero rischio. Mantieni sempre la capacita' di operare senza.

Riepilogo visuale: la catena del controllo




6. Condivisione Team: Agenti, Skill, Best Practice

Il problema della condivisione

Hai costruito un setup AI che funziona per te. Il team ne ha bisogno. Ma:

- Ogni persona ha preferenze diverse
- Le best practice evolvono velocemente
- Gli agenti/skill devono essere versionati come codice
- Il team deve poter contribuire senza rompere il setup altrui
- Serve un "single source of truth" — non 5 copie divergenti

Architettura di condivisione



Cosa condividere e come

1. CLAUDE.md di progetto (via Git — versionato, reviewato)

```
c:\Code\CLAUDE.md          ← regole globali per tutto il team
ita-dev/SPORT/sport-backend/CLAUDE.md ← regole specifiche SPORT
ita-dev/seta/seta-core/CLAUDE.md ← regole specifiche SETA
```

- Committato nel repo → versionato → review in PR → governance
- Ogni dev che usa Claude Code eredita automaticamente le regole
- Modifiche tramite PR = discussione trasparente
- Il CLAUDE.md e' il "contratto" tra team e AI

2. Slash commands condivisi (.claude/commands/)

```
.claude/
commands/
  review-pr.md      # Standard di review PR
  analyze-impact.md # Analisi impatto cross-servizio
  check-compliance.md # Verifica compliance SIAE/GDPR
  estimate-task.md   # Stima effort best/likely/worst
  triage.md          # Triage bug/incident
```

- Ogni dev puo' invocare /review-pr e ottenere lo stesso processo standardizzato
- I comandi sono versionati in Git → modifiche via PR
- Nuovi comandi = proposta in PR → review team → merge

3. Skills (.claude/skills/)

```
.claude/skills/
  triage.md      # Triage incidenti con decision tree
  to-prd.md      # Trasforma idea grezza in PRD strutturato
  migration-review.md # Review safety di una migrazione DB
  security-review.md # Audit sicurezza su un changeset
```

Le skill sono piu' complesse dei comandi: multi-step con logica condizionale, possono usare tool, documentate con esempi d'uso.

4. Knowledge Graph (Neo4j)

Il grafo contiene conoscenza strutturata queryabile:

- Architettura: componenti, relazioni, vincoli, rischi
- ADR: decisioni prese, motivazioni, alternative scartate
- Pattern: soluzioni validate che il team ha gia' usato con successo
- Anti-pattern: errori fatti — da non ripetere

Come mantenere tutto aggiornato

Principio: tratta la configurazione AI come codice

```
FLUSSO DI AGGIORNAMENTO
|
| 1. Dev modifica un CLAUDE.md / command / skill
| 2. Apre PR → review del team
| 3. Merge su main
| 4. (Opzionale) Hook post-merge: sync su Knowledge Graph
| 5. Prossima sessione AI di chiunque: regole aggiornate
|
| NESSUN SETUP MANUALE RICHIESTO AI DEV
| → Cloni il repo → hai gia' tutto
```

Tabella responsabilita'

Cosa | Dove vive | Come si aggiorna | Chi approva

Regole AI progetto | CLAUDE.md in Git | PR | Tech Lead / Architect
 Comandi condivisi | .claude/commands/ in Git | PR | Team
 Skills | .claude/skills/ in Git | PR | Team + QA
 Architettura | Neo4j + Confluence | Sync da MD | Architect
 ADR | Git (docs/) + Neo4j | PR + auto-sync | Architect

Best practice coding | CLAUDE.md + Confluence | PR + review mensile | Team
Preferenze personali | ~/.claude/memory/ | Individuale | Solo tu

Anti-pattern da evitare

Anti-pattern	Problema	Soluzione
"Ognuno ha il suo CLAUDE.md diverso"	Divergenza, standard impossibili	CLAUDE.md di progetto + memory personale separata
"Le best practice sono su Confluence e basta"	L'AI non le vede, nessuno le legge	Sync su Knowledge Graph + reference in CLAUDE.md
"Lo sa solo Mario"	Single point of failure umano	Nel grafo → queryabile da chiunque
"Aggiorniamo dopo"	Mai aggiornato	Review mensile obbligatoria in retro
"Troppi comandi/skill"	Nessuno sa cosa usare	Index documentato, naming chiaro, deprecation
"L'AI funziona bene per me"	Non replicabile	Condividi la config, non il risultato

7. Sintesi Operativa: Checklist per il Team

Setup iniziale (una volta)

- [] CLAUDE.md di progetto scritto e committato
- [] Memory personale configurata (chi sei, come lavori)
- [] Knowledge graph popolato con architettura e vincoli
- [] Comandi base condivisi (.claude/commands/) definiti
- [] Principio di ownership scritto, discusso e accettato dal team
- [] Regole di "auto-vincolo AI" nel CLAUDE.md

Per ogni sessione AI

- [] L'AI sa chi sei (verifica rapida: "chi sono io?")
- [] Le istruzioni critiche sono caricate (CLAUDE.md presente)
- [] Sai cosa stai chiedendo e perche' (obiettivo chiaro)
- [] Hai definito chi decide (tu — sempre)
- [] Hai un criterio per validare l'output prima di cominciare

Per ogni output AI importante

- [] L'AI ha dichiarato le sue assunzioni?
- [] L'AI ha marcato dove non e' sicura?
- [] L'AI ha spiegato cosa ha fatto e perche'?
- [] Hai verificato almeno un claim chiave indipendentemente?
- [] Il peggior caso se l'output e' sbagliato — e' accettabile?
- [] Se va in produzione: chi l'ha validato e firmato?

Per il team (continuo)

- [] CLAUDE.md aggiornato con le ultime decisioni?
- [] Nuove skill/comandi documentati e condivisi?
- [] Knowledge graph sincronizzato con la realta'?
- [] Feedback loop attivo (errori → correzioni → memory/regole)?
- [] Review mensile delle regole AI in sprint retro?
- [] Nessun dev "dipende dall'AI" per fare il suo lavoro base?

8. Meta-principio: L'AI e' uno Strumento, Non un Collega

Cosa l'AI NON ha

Caratteristica assente | Implicazione

Responsabilita' | Se sbaglia, il danno e' TUO
 Contesto implicito | Sa solo cio' che le dai — il resto lo inventa
 Giudizio morale | Ottimizza per la risposta, non per il risultato
 Memoria naturale | Dimentica tutto senza sistemi esterni
 Interesse a dire "non so" | Tende a rispondere comunque, anche inventando
 Continuita' | Ogni sessione e' un individuo diverso con le stesse istruzioni
 Incentivo a proteggerti | Non ha skin in the game — tu si'

Cosa l'AI HA

Caratteristica presente | Come sfruttarla

Velocita' di analisi sovrumana | Screening iniziale, correlazioni su grandi basi
 Pazienza infinita per task ripetitivi | Refactoring, review, generazione boilerplate
 Disponibilita' 24/7 | Non ha downtime, non ha umore
 Consistenza SE ben configurata | Stesse regole → stessi output (deterministico)
 Capacita' di correlare pattern | Trova connessioni che tu non vedresti per volume
 Multi-prospettiva on demand | Puo' argomentare pro E contro su richiesta

La formula

VALORE = AI + Umano Competente + Processo Solido

Senza l'umano competente: output plausibile ma potenzialmente sbagliato
 Senza il processo: nessuna garanzia di qualita' o consistenza
 Senza l'AI: lento ma sicuro
 Con tutti e tre: veloce, sicuro, scalabile

Il valore non e' nell'AI in se' — e' nella combinazione.

L'AI ti rende 3x-10x piu' veloce SE:

- Sai gia' dove vuoi andare (competenza)
- Hai regole che impediscono danni (processo)
- Rimani il validatore finale di tutto (ownership)

Se manca uno dei tre: l'AI diventa un acceleratore di errori.

9. Posizionamento 108 Vision

Cosa e' originale della piattaforma 108 AI

- Hybrid RAG (Qdrant vector + Neo4j graph) per reasoning multi-hop su conoscenza aziendale
- Desktop Agent con risk classification e OS-level capabilities
- Model routing cost-optimized (5 tier, 70-80% risparmio vs single model)
- Integrazione verticale: consulenza + piattaforma + gestione ongoing in un unico fornitore
- Principi di governance by default: baked-in nel prodotto, non opzionali

Cosa NON e' originale (table stakes)

RAG base, chatbot, dashboard, multi-tenancy. Sono requisiti minimi, non differenziatori.

Posizionamento nel mercato

- AI riduce il lavoro operativo del 30-40% — NON sostituisce lavoratori
- 108 Vision costruisce tool che automatizzano al 100% processi manuali specifici (classificazione documenti, triage email, scheduling appuntamenti)
- Il rischio principale: piattaforma troppo sofisticata per il cliente medio, troppo giovane per enterprise
- La raccomandazione: validare con 3 clienti reali PRIMA di completare Phase 4-5. Il feedback di 3 clienti paganti vale piu' di 1000 righe di codice speculativo.